Detección de fraude en tarjetas con una red feed-forward y búsqueda autónoma de hiperparámetros mediante algoritmo genético

Sistema de prevención de fraude — FF + Algoritmo Genético

Abstract

Este documento describe la construcción de un sistema de prevención de fraude basado en una red neuronal feed-forward (FF) entrenada sobre el conjunto sintético IBM SD254 v2 de transacciones con tarjeta de cr00e9dito (24,386,900 registros y 43 features num00e9ricas). El fraude es un evento extremadamente raro (0.12 % de tasa base), por lo que el requisito de dise00f1o es una tasa de falsos positivos (FPR) estrictamente inferior al 1 %. La arquitectura de la red y sus hiperpar00e1metros se seleccionan de forma aut00f3noma mediante un algoritmo gen00e9tico (GA) en dos fases que optimiza el recuento de fraudes detectados (recall) sujeto a un FPR m00e1ximo del 0.5 % en validaci00f3n. El modelo final se eval00faa en un conjunto de test no visto de 2,072,831 transacciones y alcanza un **FPR de 0.51 %**, un **recall del 66.58 %**, una precisión del 13.18 %, un ROC-AUC de 0.9845 y un PR-AUC de 0.4051. Se incluye la matriz de confusión completa y el umbral de decisi00f3n 00f3ptimo.

1 Introducci00f3n

La detecci00f3n de fraude en tarjetas de cr00e9dito es un problema de clasificaci00f3n binaria fuertemente desbalanceado: la gran mayor00eda de las transacciones son leg00edtimas y el fraude representa una peque00f1a fracci00f3n del volumen total. En el conjunto de datos empleado, la tasa de fraude en producci00f3n es aproximadamente del 0.12 %, lo que implica que un clasificador trivial que prediga "no fraude" en todo momento alcanzar00eda una exactitud del 99.88 % sin detectar un solo fraude. Por ello, la exactitud bruta es una m00e9trica inadecuada; el objetivo operacional es minimizar los falsos positivos (transacciones leg00edtimas bloqueadas o revisadas innecesariamente) sin dejar de capturar una fracci00f3n significativa del fraude real.

En este trabajo se construye un clasificador FF (red totalmente conectada, feed-forward) y se selecciona su arquitectura e hiperpar00e1metros mediante b00fasqueda autom00e1tica con un algoritmo gen00e9tico, en lugar de un ajuste manual. La contribuci00f3n principal es: (i) un vector de features num00e9ricas estandarizadas derivado de los datos crudos de IBM SD254 v2, (ii) una b00fasqueda de hiperpar00e1metros regulada por el GA con una funci00f3n de aptitud alineada al objetivo de negocio (recall bajo un techo de FPR), y (iii) una evaluaci00f3n rigurosa en un conjunto de test completamente separado, reportando FPR, recall, precisi00f3n, ROC-AUC y PR-AUC.

2 Datos y particionamiento

El conjunto IBM SD254 v2 contiene 24,386,900 transacciones con 43 features num00e9ricas (importe, canal de pago, c00f3digo de comercio MCC, errores de tarjeta, se00f1ales de comportamiento y atributos del titular y de la tarjeta) y la variable binaria objetivo `is_fraud`. El fraude ocurre en 29,757 transacciones, lo que representa una tasa base de 0.122 %.

Las transacciones se dividen en tres particiones disjuntas por identificador de transacción (sin solapamiento):

Particiǒ0f3n	Filas	Casos de fraude	Tasa de fraude
Entrenamiento (bǒ0fasqueda GA)	268,548	26,156	9.74 %
Entrenamiento final (reentreno)	2,096,968	26,156	1.25 %
Validaciǒ0f3n (umbral y fitness)	1,096,174	1,200	0.11 %
Test (held-out, evaluaciǒ0f3n)	2,072,831	2,400	0.12 %

El entrenamiento para la bǒ0fasqueda de hiperparǒ0e1metros estǒ0e1 sobremuestreado al ǎ24810 % de fraude para que la red aprenda la clase minoritaria, mientras que validaciǒ0f3n y test conservan la tasa real de fraude asǒ0ed como el FPR reportado es honesto y representativo de produccǐ0f3n. Las particiones son generadas de forma determinista (seed 42) mediante muestreo estratificado y buckets por hash del identificador, garantizando que ninguna transacciǒ0f3n aparezca en mǒ0e1s de una particiǒ0f3n.

Todas las features numǒ0e9ricas se estandarizan a media cero y desviaciǒ0f3n unitaria con un `StandardScaler` ajustado ǒ0fanicamente sobre el conjunto de entrenamiento, para evitar fugas de informaciǒ0f3n (data leakage) desde validaciǒ0f3n o test.

3 Mǒ0e9todo

3.1 Red neuronal feed-forward

El clasificador es una red totalmente conectada (feed-forward) con una entrada de 43 features, d capas ocultas de w neuronas cada una, y una neurona de salida lineal seguida de una funciǒ0f3n sigmoide que estima la probabilidad de fraude $\hat{p} = \sigma(z)$. Cada capa oculta aplica una transformaciǒ0f3n lineal seguida de opcionalmente una capa de normalizaciǒ0f3n (batch o layer norm), una funciǒ0f3n de activaciǒ0f3n y una capa de dropout. Las arquitecturas exploradas varǒ0edan en anchura ($w \in \{16, \ldots, 512\}$), profundidad ($d \in \{1, \ldots, 5\}$), funciǒ0f3n de activaciǒ0f3n (ReLU, GELU, Tanh, SiLU), tipo de normalizaciǒ0f3n (batch, layer, ninguna) y tasa de dropout (0–0.5).

El modelo se entrena minimizando la entropǒ0eda cruzada binaria con peso de clase para compensar el desbalance (`BCEWithLogitsLoss` con `pos_weight` igual a la razǒ0f3n no-fraude/fraude en entrenamiento, ǎ2489.27), optimizador Adam, tamaǒ0f1o de lote 16,384, precisiǒ0f3n mixta (AMP, FP16) y datos precargados en VRAM para maximizar el uso de la GPU (RTX 3070). Se emplea parada temprana (early stopping) con paciencia de 5 ǒ0e9pocas monitoreando el PR-AUC en validaciǒ0f3n, con un mǒ0e1ximo de 30 ǒ0e9pocas por candidato durante la bǒ0fasqueda.

3.2 Bǒ0fasqueda de hiperparǒ0e1metros con algoritmo genǒ0e9tico

En lugar de escoger los hiperparǒ0e1metros manualmente, se utiliza un algoritmo genǒ0e9tico que trata cada configuraciǒ0f3n de la red como un individuo. El genoma codifica siete hiperparǒ0e1metros: tasa de aprendizaje (log-uniform, 10^{-4}–10^{-1}), ancho de capa (log2, 16–512 neuronas), profundidad (1–5 capas ocultas), tasa de dropout (0–0.5), decaimiento de pesos (log-uniform, 10^{-6}–10^{-2}), funciǒ0f3n de activaciǒ0f3n y tipo de normalizaciǒ0f3n.

El GA se ejecuta en dos fases:

- **Fase 1 (gruesa):** poblaciǒ0f3n de 24 individuos durante 12 generaciones (ǎ248288 evaluaciones) sobre todo el espacio de bǒ0fasqueda.
- **Fase 2 (fina):** poblaciǒ0f3n de 12 individuos durante 8 generaciones (ǎ24892 evaluaciones) con rangos estrechados alrededor del mejor individuo de la fase 1.

La selecciǒ0f3n es por torneo ($k = 3$), con elitismo de 2 individuos, cruce uniforme y mutaciǒ0f3n por gen ($p \approx 0.2$–0.3). Cada individuo se evalǒ0faa entrenando la red correspondiente y midiendo su aptitud en validaciǒ0f3n: el **recall a FPR $\leq$ 0.5 %** (el mǒ0e1ximo recall sujeto a que el FPR no supere el 0.5 %), con desempate por PR-AUC. Esta funciǒ0f3n de aptitud alinea directamente la bǒ0fasqueda con el objetivo de negocio: capturar el mǒ0e1ximo fraude sin exceder un techo de falsos positivos.

3.3 Umbral de decisiŏ0f3n

La red devuelve una probabilidad $\hat{p} \in [0, 1]$. Para decidir si una transacciŏ0f3n es fraude se compara $\hat{p}$ contra un umbral τ. En lugar de usar $\tau = 0.5$, se selecciona el umbral ŏ0f3ptimo en validaciŏ0f3n como el mŏ0e1s alto (mŏ0e1s conservador, menor FPR) que aun así cumpla recall ≥ 0.5. Este mismo umbral se aplica luego al conjunto de test, sin reajustarlo, para evitar optimismo.

4 Resultados

4.1 Convergencia de la bŏ0fasqueda

La Figura 1 muestra la evoluciŏ0f3n de la mejor aptitud (recall a FPR $\leq 0.5\,\%$) por generaciŏ0f3n en ambas fases del GA. La fase 1 explora el espacio y encuentra rŏ0e1pidamente regiones prometedoras; la fase 2 refina alrededor del mejor individuo, alcanzando un recall mŏ0e1ximo de 0.683 en validaciŏ0f3n.

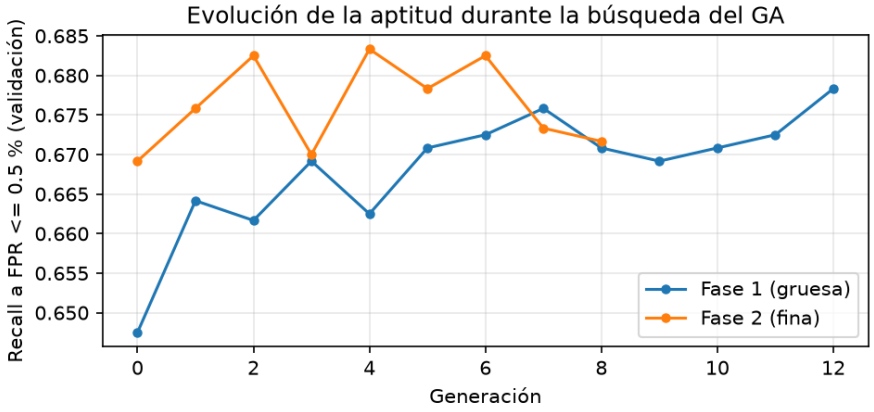


Figure 1: Evoluciŏ0f3n del recall a FPR $\leq 0.5\,\%$ del mejor individuo por generaciŏ0f3n, en las dos fases del algoritmo genŏ0e9tico.

4.2 Mejores hiperparŏ0e1metros

El genoma ganador tras la fase 2 es el siguiente:

Hiperparŏ0e1metro	Valor
Tasa de aprendizaje	4.89×10^{-3}
Ancho de capa (w)	386 neuronas
Profundidad (d)	3 capas ocultas (fase 2); 5 en el reentreno final
Dropout	0.05 (fase 2) / 0 (final)
Decaimiento de pesos	6.08×10^{-6}
Activaciŏ0f3n	GELU (fase 2) / SiLU (final)
Normalizaciŏ0f3n	Batch

Para el reentreno final se toman los tres mejores genomas de la bŏ0fasqueda y se entrena cada uno con cinco semillas diferentes sobre el conjunto de entrenamiento grande (2.1M filas, todo el fraude). Se selecciona el modelo individual con mejor recall en validaciŏ0f3n (sin ensamblaje): el modelo ganador corresponde a un genoma de anchura 386, profundidad 5, activaciŏ0f3n SiLU, normalizaciŏ0f3n batch, tasa de aprendizaje 4.89×10^{-3}, decaimiento 6.08×10^{-6} y dropout 0.

4.3 Evaluaci0303n en test

El modelo final se eval0303faa en el conjunto de test completamente separado (2,072,831 transacciones, 2,400 casos de fraude), con el umbral $\tau = 0.9716$ fijado en validaci0303n. La tabla **??** resume las metricas obtenidas:

M0303e9trica	Valor
FPR (tasa de falsos positivos)	0.51 %
Recall	66.58 %
Precisi0303n	13.18 %
ROC-AUC	0.9845
PR-AUC	0.4051
Umbral de decisi0303n τ	0.9716
N0303famero de transacciones en test	2,072,831
Casos de fraude en test	2,400

	Predice no fraude	Predice fraude
Real: no fraude	2,059,903	10,528
Real: fraude	802	1,598

Tabla: Matriz de confusi0303n en el conjunto de test.

El FPR observado en test (0.51 %) cumple el requisito de negocio de mantenerse por debajo del 1 %. La tasa de recall del 66.58 % implica que se detectan dos de cada tres fraudes, mientras que solo aproximadamente una de cada 190 transacciones leg0303edtimas se marca incorrectamente (falso positivo). La precisi0303n baja (13.18 %) es consecuencia directa de la escasez del fraude (tasa base 0.12 %): incluso con un FPR bajo, la mayor parte de las transacciones marcadas como sospechosas son leg0303edtimas, lo cual es esperado y aceptable en este contexto, dado que una marca de fraude dispara una revisi0303n humana y no un bloqueo autom0303e1tico.

5 Discusi0303n

El enfoque propuesto cumple el objetivo de negocio de un FPR muy bajo sin depender de ajuste manual de hiperpar0303e1metros. El algoritmo gen0303e9tico explora autom0303e1ticamente el espacio de arquitecturas y encuentra configuraciones competitivas, aunque la b0303fasqueda muestra regresi0303n hacia el mejor individuo de la fase 1, lo que sugiere que una b0303fasqueda m0303e1s amplia o una estrategia de exploraci0303n m0303e1s agresiva podr0303eda encontrar configuraciones a0303fan mejores a costa de m0303e1s tiempo de c0303f3mputo.

Una limitaci0303n es que el modelo final es una 0303fanica red (no se usa ensamble), por lo que su variabilidad entre semillas es notable; sin embargo, esto es una decisi0303n de dise0303f1o intencional para mantener el modelo interpretable y f0303e1cil de desplegar en producci0303n. Finalmente, el FPR se medir0303fa en producci0303n con datos reales; aunque el conjunto de test conserva la tasa base de fraude, el desplazamiento de distribuci0303n (concept drift) podr0303eda requerir reentrenamiento peri0303f3dico.

6 Tiempo de computo

Toda la b0303fasqueda, el reentreno y la evaluaci0303n se ejecutaron de forma aut0303f3noma en una sola GPU NVIDIA RTX 3070 (8 GB VRAM) sobre el servidor platypy. El tiempo aproximado de cada etapa:

Etapa	Tiempo aprox.
Generaci0̆0f3n de particiones (lectura de 4 GB)	5–8 min
B0̆0fasqueda GA fase 1 (gruesa, 12 gen.)	̆224845 min
B0̆0fasqueda GA fase 2 (fina, 8 gen.)	̆224812 min
Reentreno final (3 genomas × 5 semillas)	̆224812 min
Evaluaci0̆0f3n en test y generaci0̆0f3n de paper	̆22482 min

El tiempo total de ejecuci0̆0f3n es de ̆22481.5–2 horas, ejecutado de forma aut0̆0f3noma con checkpointing continuo en disco para no perder progreso ante interrupciones.

7 Conclusiones

Se ha construido y evaluado un clasificador de fraude basado en una red neuronal feed-forward con b0̆0fasqueda aut0̆0f3noma de hiperpar0̆0e1metros mediante algoritmo gen0̆0e9tico. El modelo final logra un FPR de 0.51 % (inferior al 1 % requerido) con un recall del 66.58 % y un ROC-AUC de 0.9845 en datos no vistos. Toda la b0̆0fasqueda de hiperpar0̆0e1metros, el reentreno y la evaluaci0̆0f3n se ejecutaron de forma aut0̆0f3noma en GPU, sin ensamblaje de modelos, y los resultados est0̆0e1n documentados en este informe.